

Final Report: WiDS Global Datathon 2026

2021320111 홍태선
2022390707 배지연
2024100120 손충기

1. 문제 정의

본 프로젝트는 산불이 초기 관측 후 12 / 24 / 48 / 72시간 내에 대피구역에 도달할 확률을 예측하는 것을 목표로 한다. 예측 대상은 단순한 이진 분류가 아니라 시간대별 누적 도달 확률이며, 관측 기간 내에 도달하지 않은 사건은 중도절단(right-censoring)으로 처리된다. 이러한 구조는 전형적인 생존분석 문제에 해당하며, 일반적인 분류 모델보다 생존분석 기반 접근이 적합하다. 학습 데이터는 221개 산불 사건으로, 각 사건의 초기 5시간 관측 정보(거리, 확산량, 이동 방향 등)를 기반으로 이후 도달 여부와 시간을 예측한다. 평가 지표는 C-index와 censoring-aware Brier Score를 결합한 Hybrid Score: $0.3 \times \text{C-index} + 0.7 \times (1 - \text{Weighted Brier})$ 이다.

2. 적용한 방법론 설명

- Data engineering pipeline

본 프로젝트의 데이터 엔지니어링 파이프라인은 다음과 같은 단계로 구성된다.

1) Feature Engineering

EDA 단계에서 `dist_min_ci_0_5h`(초기 5시간 내 대피구역과의 최소 거리)가 강한 우측 편향과 극단값을 보임을 확인하였다. 해당 변수를 그대로 투입할 경우 모델이 소수의 극단 샘플에 과도하게 반응할 수 있어, `log1p` 변환을 적용하여 파생 피처를 생성하였다:

```
log1p_dist_min_ci_0_5h=log(1+dist_min_ci_0_5h)
```

원본 변수(`dist_min_ci_0_5h`)는 이후 피처 집합에서 제외하여 정보 중복을 방지하였다. 식별자(`event_id`), 타겟 변수(`event`, `time_to_hit_hours`), 범주형 변수를 추가로 제외한 결과, 최종 모델에 투입된 피처 수는 총 34개이다.

2) 모델별 전처리

Lasso-Cox와 RSF는 동일한 데이터를 사용하면서도 알고리즘 특성에 따라 서로 다른 전처리 파이프라인을 적용하였다. 이를 위해 `fit_preprocess()` (Cox용)와 `fit_preprocess_rsf()` (RSF용) 두 가지 함수를 별도 설계하여, 데이터 누수를 방지하기 위해 각 fold의 `train split`에서만 전처리 통계를 추정하고 `validation/test`에 적용하는 구조를 채택하였다.

전처리	Lasso-Cox	Random Survival Forest
결측치 처리	Median Imputation	Median Imputation
상관 기반 변수 제거	corr > 0.95 제거	기본 비활성 (옵션:0.98)

저분산 변수 제거	$\text{var} < 1\text{e-}6$	$\text{var} < 1\text{e-}6$
스케일링	StandardScaler 적용	미적용

RSF에 StandardScaler를 적용하지 않은 이유는, 트리 기반 모델은 분기 조건을 특징값의 순서에만 의존하므로 선형 변환에 대해 불변(scale-invariant)이기 때문이다. 반면 Cox 모형은 회귀 계수의 수치적 안정성이 스케일에 영향을 받으므로 정규화가 필수적이다.

상관 기반 변수 제거 시, log1p_dist_min_ci_0_5h는 핵심 피처로 판단하여 protected feature로 지정하였다. 해당 변수가 다른 변수와 높은 상관을 보이더라도 제거되지 않도록 설정함으로써, 가장 강한 예측력을 가진 거리 정보가 파이프라인에서 손실되는 것을 방지하였다.

3) Survival Target Construction

scikit-survival의 RSF 모델은 일반적인 분류·회귀 타겟이 아닌 구조화된 생존 배열을 요구한다. 이에 따라 각 학습 샘플을 (event: bool, time: float) 쌍으로 구성된 구조체(Surv.from_arrays)로 변환하였다. 이벤트가 관측 기간 내에 발생하지 않은 사건은 중도절단(right-censoring)으로 처리되어 모델이 불완전한 정보를 가진 샘플도 학습에 포함할 수 있도록 하였다. 학습 데이터 221건 중 event=1은 69건(31.2%), event=0(censored)은 152건(68.8%)으로 불균형이 존재하여 이를 Stratified K-Fold 교차검증의 기준으로 활용하였다.

4) Evaluation Metric Design

대회 공식 평가 지표를 파이프라인 내에서 직접 구현하였다. 각 시간 지평 H(Horizon)에 대한 censoring-aware Brier Score 계산 규칙은 다음과 같다.

- event=1, time $\leq$ H: label=1, 포함
- event=1, time > H: label=0, 포함
- event=0, time $\geq$ H: label=0, 포함
- event=0, time < H: 절단 이전 종료, 제외

대회 공식에 따라 Weighted Brier Score는 $0.3 \times \text{Brier@24h} + 0.4 \times \text{Brier@48h} + 0.3 \times \text{Brier@72h}$ 로 산출하였다(12h는 메트릭에서 제외). 최종 Hybrid Score는 $0.3 \times \text{C-index} + 0.7 \times (1 - \text{Weighted Brier})$ 로 정의하였다. 이를 통해 각 지평별 실질적인 예측 정확도를 측정하고, 하이퍼파라미터 탐색의 최적화 목표로 활용하였다.

5) Hyperparameter 탐색

각 모델의 핵심 하이퍼파라미터를 교차검증 기반으로 탐색하였다.

Lasso-Cox: penalizer(L1 정규화 강도)를 [0.02, 0.03, 0.04, 0.05, 0.06, 0.08] 범위에서 비교하였다. penalizer=0.06은 fold 4에서 수렴 오류가 발생하여 제외되었으며, 최종적으로 penalizer=0.04가 OOF Hybrid Score 0.9510으로 최적 성능을 기록하였다. 비교적 약한 정규화 강도가 선택된 것은 소규모 데이터임에도 핵심 변수(log1p_dist_min_ci_0_5h)의 신호가 충분히 강해 과도한 정규화보다 정보 보존이 성능 향상에 유리했음을 보여준다.

RSF: n_estimators $\times$ min_samples_leaf $\times$ max_features 조합으로 18개 후보를 그리드 서치한 결과, 최적 파라미터는 n_estimators=480, max_depth=None(무제한),

min_samples_leaf=3, max_features=0.8 로 확정되었다(Hybrid Score 0.972).
max_features='sqrt'는 Brier Score가 크게 악화되어 제외하였고, max_features=0.8이
분산-편향 균형 측면에서 최적임을 확인할 수 있었다.

6) Stratified 5-Fold OOF 교차검증

221개의 제한된 학습 샘플에서 안정적인 성능 추정을 위해 Stratified K-Fold(k=5, seed=42)
기반의 Out-of-Fold(OOF) 교차검증을 구성하였다. 이벤트 발생 비율(약 31%)을 기준으로
층화 분할을 적용하여 각 폴드에서 클래스 불균형이 균등하게 유지되도록 하였다. 각
폴드에서 학습된 모델의 검증 예측값을 누적하여 전체 학습 데이터에 대한 OOF 확률
행렬(221 × 4)을 구성하였으며, 이를 기반으로 C-index와 Brier Score를 산출하였다.

7) 생존 함수(Survival Function) 기반 확률 추출

RSF 모델의 predict_survival_function은 각 샘플에 대한 계단함수 형태의 생존함수 S(t)를
반환한다. 각 시간 지평 H에서의 이벤트 발생 확률은 $P(T \leq H) = 1 - S(H)$ 로 계산하였다.
이때 일부 샘플에서 생존함수의 정의 구간이 H에 미치지 못하는 경우가 발생할 수 있어, $t = \min(H, sf.x.max())$ 로 가능한 최댓값을 사용하는 경계 처리를 추가하였다. 추출된 모든
확률값은 [0, 1] 범위로 클리핑하였다.

8) 단조성 보정

추출된 확률값은 생존 이론의 요건상 시간이 경과할수록 단조 증가해야 한다($P(T \leq 12h) \leq P(T \leq 24h) \leq P(T \leq 48h) \leq P(T \leq 72h)$). 수치 계산 과정에서 일부 샘플에 역전 현상이 발생할 수
있으므로 np.maximum.accumulate를 시간 축 방향으로 적용하였다. 이러한 보정은 OOF
예측 단계와 최종 테스트 예측 단계 모두에 일관되게 적용되었다.

9) 앙상블

최종 제출 결과 csv는 RSF 단독 모델과 Lasso-Cox Baseline 모델의 예측 확률을 선형
결합하여 생성하였다. RSF와 Cox 두 모델은 같은 생존분석 프레임워크 내에서 상호
보완적인 특성을 가진다. RSF는 비선형 상호작용을 포착하는 반면, Cox 모델은 선형적 위험
구조를 안정적으로 모델링한다. 캐글 리더보드 단독 제출 결과 Lasso-Cox는 Public Score
0.935, RSF는 0.962를 기록하였다. 최적 앙상블 가중치를 탐색한 결과 $0.8 * RSF + 0.2 * Cox$
조합이 Public Score 0.963으로 가장 높은 성능을 보여 최종 제출물로 채택하였다. 앙상블
후에도 단조성 보정을 재적용하여 최종 확률값의 일관성을 유지하였다.

3. 최종 결과 및 해석

- Baseline 모델과의 성능 비교


Model	OOF C-index	Weighted Brier	Hybrid Score	Public Score
Lasso-Cox	0.9251	0.0379	0.9510	0.9358
RSF	0.9423	0.0143	0.9727	0.9623
Ensemble	0.9435	0.0156	0.9722	0.9632

본 프로젝트에서는 **Lasso-Cox**를 **baseline** 모델로 설정하고, 동일한 평가 지표를 기준으로 **RSF** 및 **ensemble**과의 성능을 비교하였다. **Lasso-Cox**는 **OOF C-index 0.9251, Weighted Brier 0.0379, Hybrid Score 0.9510, public score 0.9358**을 기록하였다. **Lasso-Cox**는 생존 분석에서 널리 활용되는 비례 위험 모델로, 정규화를 통해 변수 선택과 과적합 억제를 동시에 수행한다는 점에서 해석 가능성과 일반화 측면에서 강점을 갖는다. 위험 순위화와 시간대별 생존 확률 예측을 모두 수행할 수 있는 구조임에도 불구하고, 선형 가정에 기반한 모델 특성상 변수 간 비선형 관계 및 고차 상호작용을 충분히 반영하는 데는 구조적 한계가 존재하며, 이후 모델과의 비교를 통해 해당 한계가 성능 차이로 나타남을 확인할 수 있었다.

RSF는 모든 지표에서 **baseline**을 상회하며 단일 모델 기준 가장 높은 내부 검증 성능을 달성하였다. **OOF C-index 0.9423, Weighted Brier 0.0143, Hybrid Score 0.9727, public score 0.9623**으로, **Lasso-Cox** 대비 **C-index는 0.0172, Weighted Brier는 0.0236, Hybrid Score는 0.0217, public score는 0.0265** 향상되었다. 특히 **Weighted Brier Score**의 개선 폭이 두드러지는데, 이는 **RSF**가 단순한 위험 순위화를 넘어 시간대별 생존 확률의 보정 측면에서도 우수한 성능을 보였음을 의미한다. 거리, 방향성, 초기 성장 특성 간의 비선형 관계 및 변수 간 상호작용을 트리 기반 앙상블 구조를 통해 효과적으로 포착한 결과로 해석되며, 선형 모델이 놓친 복잡한 데이터 패턴을 반영할 수 있었던 점이 성능 향상의 주요 요인으로 판단된다.

Ensemble은 **OOF C-index 0.9435, Weighted Brier 0.0156, Hybrid Score 0.9722, public score 0.9632**를 기록하였다. 내부 검증 기준 **Hybrid Score**는 **0.9722**로 **RSF**의 **0.9727**에 비해 소폭 낮게 나타났으나, 최종 제출 기준인 **public score**에서는 **0.9632**로 세 모델 중 가장 높은 수치를 달성하였다. 이는 **Lasso-Cox**와 **RSF** 각각의 예측을 결합함으로써 개별 모델이 갖는 편향과 분산의 상충 관계를 완화하고, 학습에 사용되지 않은 미지 데이터에 대한 일반화 성능이 개선된 결과로 판단된다.


- 결과를 보여주는 시각화 자료



[Figure 1] Hybrid Score 및 Public Score 비교

Figure 1은 세 모델의 **Hybrid Score**와 **Public Score**를 나란히 비교한 막대 그래프이다. **Lasso-Cox**는 **Hybrid Score 0.9510, Public Score 0.9358**로 두 지표 간 격차가 상대적으로 크게 나타난 반면, **RSF**와 **Ensemble**은 각각 **0.97**대의 **Hybrid Score**와 **0.96**대의 **Public Score**를 기록하며 내부 검증과 외부 제출 간 격차가 크게 줄어든 양상을 보인다. 이는 **RSF**와

Ensemble이 학습 데이터에 과적합되지 않고 미지 데이터에도 일관된 성능을 유지하였음을 시각적으로 확인할 수 있는 결과이다.




[Figure 2] OOF C-index 및 Weighted Brier Score 비교

Figure 2는 OOF C-index와 Weighted Brier Score를 각각 별도의 축으로 나타낸 비교 그래프이다. OOF C-index에서는 Lasso-Cox(0.9251) 대비 RSF(0.9423)와 Ensemble(0.9435)이 뚜렷하게 높은 수치를 기록하였으며, RSF와 Ensemble 간의 차이는 미미한 수준임을 확인할 수 있다. Weighted Brier Score에서는 낮을수록 우수한 성능을 의미하는데, Lasso-Cox(0.0379)가 RSF(0.0143) 및 Ensemble(0.0156)에 비해 현저히 높은 값을 보여 생존 확률 보정(calibration) 측면에서 큰 차이가 존재함을 명확히 드러낸다. 특히 Weighted Brier Score의 개선 폭은 단순한 순위 예측 성능을 넘어, 시간대별 생존 확률의 정확도 면에서 트리 기반 모델이 선형 모델을 크게 앞섰음을 보여주는 핵심 근거로 작용한다.

성능 지표 비교와 더불어, 최종 제출 모델의 예측 결과가 시간축에 따라 어떠한 분포를 보이는지 확인하기 위해 추가적인 시각화를 수행하였다.[Figure 3] 최종 제출 모델로 채택된 앙상블(RSF 0.8 + Cox 0.2)의 예측 확률 분포를 시간대별로 시각화하였다. 그 결과, 12시간, 24시간, 48시간, 72시간으로 갈수록 예측 확률의 중앙값과 전반적인 분포가 점진적으로 증가하는 경향을 확인할 수 있었다. 이는 시간이 경과할수록 대피구역 도달 확률이 누적적으로 반영된다는 점에서 생존분석 기반 예측의 특성과 일관된다.

또한 각 시간대별 분포 차이를 통해 사건별 위험 수준이 동일하지 않으며, 최종 앙상블 모델이 이를 구분하여 예측하고 있음을 확인할 수 있다. 일부 구간에서는 분포 범위가 넓게 나타나 예측의 불확실성이 존재함을 시사하지만, 전반적으로 시간 흐름에 따른 확률 구조가 안정적으로 유지되는 것을 확인하였다.



[Figure 3] 최종 앙상블 모델의 시간대별 예측 확률 분포

- Limitation & Future Work

본 프로젝트는 초기 5시간 산불 관측 정보만으로도 12h, 24h, 48h, 72h 이내 대피구역 도달 확률을 유의미하게 예측할 수 있음을 보여주었다. 이는 단순히 도달 여부를 분류하는 수준을 넘어, 시간 지평별 누적 위험 확률을 제시함으로써 재난 대응에서 위험 우선순위를 설정하고 확률 기반으로 의사결정을 지원할 수 있음을 시사한다. 또한 실험 결과를 통해 산불 위험 예측에서는 선형 **baseline**만으로는 충분하지 않으며, 비선형 관계와 변수 간 상호작용을 반영한 모델링 및 앙상블 전략이 일반화 성능 향상에 효과적임을 확인하였다.

다만 본 연구는 221개 산불 사건을 기반으로 수행되어 데이터 규모 측면에서 일반화에 한계가 있을 수 있으며, 입력 변수 역시 초기 5시간 관측 정보에 한정되어 있어 이후 확산 경로 변화나 장기적인 전개 양상을 충분히 반영하지 못했다. 향후에는 기상 조건, 식생 유형 등 외부 변수를 추가하고 더 다양한 산불 사례 데이터를 확보함으로써 모델의 확장성과 신뢰도를 높일 필요가 있다. 또한 **calibration**, 보다 정교한 **ensemble** 전략, 반복적인 제출 검증을 통해 로컬 성능과 실제 제출 성능 간의 차이를 줄이는 방향으로 추가적인 개선이 가능할 것으로 보인다.